LAPORAN UTS
PENGELOMPOKAN POLA PENGGUNAAN TRANSPORTASI UMUM JAKARTA BERDASARKAN WAKTU DAN JENIS LAYANAN MENGGUNAKAN CLUSTERING

PEMBELAJARAN MESIN

Oleh:
Kelompok 4

Anggota:
Rifky Ghifari Siregar (231112918)
Indra Jeremia Tinambunan (231112760)
Selamet Riyadi (231112132)



SEMESTER GANJIL

TA. 2026-2027

DAFTAR ISI

DAFTAR ISI 1
DAFTAR GAMBAR 3
DAFTAR TABEL 4
ISI LAPORAN 5
A. Problem Formulation 5
Masalah yang ingin diselesaikan 5
Alasan masalah ini penting 5
Tujuan proyek 5
Target yang ingin dihasilkan 6
Jenis pendekatan machine learning 6
Batasan 6
B. Dataset dan Data Understanding 6
Sumber dataset 6
Ukuran dan struktur data 7
Deskripsi fitur 7
Kelengkapan data 8
Statistik dasar per moda 8
Masalah kualitas data yang ditemukan 8
C. EDA dan Initial Findings 9
1. Rata-rata penumpang per moda 10
2. Distribusi jumlah penumpang (histogram) 10
3. Sebaran penumpang per moda (boxplot) 11
4. Hari kerja vs akhir pekan per moda 12
5. Tren bulanan per moda 13
6. Hubungan weekday dan weekend (scatter plot) 14
7. Korelasi pola harian antarmoda 15
Ringkasan temuan awal EDA 15
D. Preprocessing 16
Penanganan nilai hilang dan data bermasalah 16
Penanganan outlier 17
Transformasi dan scaling 17
Pencegahan data leakage 17
E. Initial Feature Engineering 18
F. Baseline dan Initial Candidate Models 20

Baseline: K-Means k = 3 20
Kandidat model awal 21
Dendrogram Agglomerative 22
G. Evaluation Design 22
Pembagian data 22
Metode validasi: uji kestabilan 5-fold pada tanggal 23
Metrik evaluasi 23
Alasan pemilihan metrik 24
H. Initial Results and Analysis 24
1. Eksperimen jumlah cluster (k = 2 sampai 6) 24
2. Perbandingan model pada k = 4 25
3. Analisis sensitivitas fitur 26
4. Hasil uji kestabilan 27
5. Profil cluster terpilih (K-Means k = 4) 27
6. Pemeriksaan PCA 28
Keterbatasan dan hal yang perlu diperbaiki 29
I. Documentation and Next Plan 29
Dokumentasi 29
Catatan eksperimen 30
Rencana pekerjaan setelah UTS sampai UAS 30

DAFTAR GAMBAR

Gambar 1 Rata-rata Penumpang per Hari Tiap Jenis Moda 10
Gambar 2 Histogram Jumlah Penumpang Sebelum dan Sesudah Transformasi Log 10
Gambar 3 Boxplot Sebaran Penumpang per Jenis Moda (Skala Log) 11
Gambar 4 Perbandingan Penumpang Weekday vs Weekend per Moda 12
Gambar 5 Tren Rata-rata Penumpang Harian per Bulan 13
Gambar 6 Scatter Plot Rata-rata Weekday vs Weekend per Moda 14
Gambar 7 Heatmap Korelasi Jumlah Penumpang Harian Antarmoda 15
Gambar 8 Hasil Baseline K-Means k = 3 dan Silhouette per Moda 21
Gambar 9 Dendrogram Agglomerative Clustering (Ward) 22
Gambar 10 Elbow Method, Silhouette Score, dan Davies-Bouldin Index untuk k = 2 sampai 6 25
Gambar 11 Hasil K-Means k = 4 dan Heatmap Profil Cluster 27

DAFTAR TABEL

Tabel 1 Identifikasi Proyek 6
Tabel 2 Ringkasan Dataset 7
Tabel 3 Deskripsi Kolom Dataset 7
Tabel 4 Statistik Jumlah Penumpang per Hari per Moda (CV = std/mean) 8
Tabel 5 Temuan Kualitas Data 8
Tabel 6 Median Penumpang Weekday vs Weekend 12
Tabel 7 Langkah Preprocessing 16
Tabel 8 Data Setelah Preprocessing (Siap Clustering) 17
Tabel 9 Fitur Hasil Rekayasa 18
Tabel 10 Nilai Fitur per Moda (Skala Asli) 19
Tabel 11 Konfigurasi Baseline 20
Tabel 12 Hasil Baseline K-Means k = 3 (Inertia 4,738; Silhouette 0,435) 20
Tabel 13 Kandidat Model Awal 21
Tabel 14 Metrik Evaluasi 23
Tabel 15 Hasil K-Means dan Agglomerative Ward untuk k = 2 sampai 6 (keduanya identik) 24
Tabel 16 Perbandingan Baseline dan Kandidat Model 25
Tabel 17 Analisis Sensitivitas Fitur (K-Means) 26
Tabel 18 Hasil Uji Kestabilan 5-Fold pada Tanggal 27
Tabel 19 Profil Cluster K-Means k = 4 28
Tabel 20 Artefak Proyek 29
Tabel 21 Catatan Eksperimen 30
Tabel 22 Rencana Pasca-UTS 30

ISI LAPORAN

A. Problem Formulation

Masalah yang ingin diselesaikan

Angkutan umum Jakarta terdiri dari beberapa moda yang melayani kebutuhan berbeda. KRL, MRT, dan TransJakarta dipakai untuk perjalanan kerja dan sekolah, Bus Sekolah hanya beroperasi pada hari sekolah, sedangkan Kapal (Kepulauan Seribu) lebih banyak dipakai untuk wisata. Jumlah penumpang antarmoda juga berbeda sangat jauh, dari sekitar 3 ribu sampai hampir 1 juta penumpang per hari, dan pola hari kerja dan akhir pekan pun berbeda.

Sampai saat ini belum diketahui secara objektif apakah moda-moda tersebut dapat dikelompokkan berdasarkan pola penggunaannya. Proyek ini mengkaji apakah ada kelompok moda dengan pola penggunaan yang mirip, dan apakah kelompok itu berkaitan dengan waktu (hari kerja vs akhir pekan) dan jenis layanan.

Alasan masalah ini penting

1. Pengelompokan yang diturunkan dari data dapat menjadi dasar pengaturan armada dan jadwal, misalnya menambah frekuensi moda komuter pada hari kerja dan menambah armada moda rekreasi saat akhir pekan atau libur panjang.
2. Moda dengan pola serupa dapat dikelola dengan kebijakan yang serupa, sehingga perencanaan menjadi lebih sederhana.
3. Hasil pengelompokan membantu memahami peran tiap moda dalam sistem transportasi Jakarta, bukan hanya dari volume penumpangnya.

Tujuan proyek

Mengelompokkan jenis moda angkutan umum Jakarta berdasarkan skala penumpang, perbedaan hari kerja dan akhir pekan, serta kestabilan harian, lalu menafsirkan karakteristik setiap kelompok.

Pertanyaan analisis yang ingin dijawab:

1. Bagaimana distribusi dan tren penumpang setiap moda?
2. Apakah pola hari kerja dan akhir pekan berbeda antarmoda?
3. Apakah moda dapat dikelompokkan menjadi cluster yang masuk akal dan dapat ditafsirkan?

Target yang ingin dihasilkan

- Sejumlah cluster moda yang stabil, beserta profil setiap cluster (skala penumpang, rasio akhir pekan/hari kerja, dan kestabilan harian).
- Interpretasi setiap cluster dalam bahasa operasional, misalnya "komuter massal" atau "rekreasi", beserta implikasinya bagi pengaturan armada.

Jenis pendekatan machine learning

Proyek ini menggunakan unsupervised learning (clustering), karena data tidak memiliki label atau target kelompok. Kualitas cluster dinilai dengan metrik internal (silhouette score, Davies-Bouldin, Calinski-Harabasz, Elbow) dan dengan kemudahan interpretasi.

Tabel 1 Identifikasi Proyek

Informasi	Keterangan
Project ID	B02
Topik	Pola penggunaan transportasi umum berdasarkan waktu dan jenis layanan
Unit analisis	Jenis moda (8 moda), hasil agregasi dari 7.061 data harian
Target/label	Tidak ada (clustering)
Metode	K-Means, Agglomerative Clustering, Gaussian Mixture

Batasan

- Data hanya berisi jumlah penumpang per hari per moda, tanpa data per jam, rute, atau stasiun.
- Periode data 1 Januari 2024 sampai 31 Agustus 2026, dan MIKROTRANS baru tercatat sejak Januari 2026.
- Hanya ada 8 moda, sehingga hasil dan metrik clustering perlu dibaca dengan hati-hati.
- Tidak ada label kebenaran, sehingga kualitas cluster dinilai dari metrik internal dan interpretasi.

B. Dataset dan Data Understanding

Sumber dataset

Dataset yang digunakan adalah "Jumlah Penumpang Angkutan Umum yang Terlayani per Hari" dari portal Satu Data Jakarta milik Pemerintah Provinsi DKI Jakarta.

Dataset ini bersifat real-world, yaitu data resmi jumlah penumpang yang tercatat oleh operator angkutan umum.

Tautan: https://satudata.jakarta.go.id/open-data/detail?kategori=dataset&page_url=jumlah-penumpang-angkutan-umum-yang-terlayani-perhari&data_no=1

File yang diunduh berformat .xls (berisi tabel HTML) dan dibaca dengan pd.read_html().

Ukuran dan struktur data

Tabel 2 Ringkasan Dataset

Keterangan	Nilai
Jumlah observasi (baris)	7.061
Jumlah kolom	4
Periode	1 Januari 2024 - 31 Agustus 2026 (974 hari)
Jumlah moda	8
Unit observasi data mentah	Satu moda pada satu tanggal
Unit analisis clustering	Satu jenis moda (8 baris setelah agregasi)
Target/label	Tidak ada

Deskripsi fitur

Tabel 3 Deskripsi Kolom Dataset

Kolom	Tipe	Deskripsi
periode_data	int64	Periode bulan data dalam format YYYYMM, misalnya 202402
tanggal	datetime	Tanggal pencatatan jumlah penumpang
jenis_moda	object (kategorikal)	Jenis moda: TRANSJAKARTA, KRL, MRT, LRT, MIKROTRANS, BUS SEKOLAH, KCI COMMUTER BANDARA, KAPAL
jumlah_penumpang_per_hari	int64	Jumlah penumpang yang terlayani pada tanggal tersebut

Karena tidak ada target, variabel utama yang dianalisis adalah jumlah_penumpang_per_hari, yang dikaitkan dengan waktu (tanggal, diturunkan menjadi hari kerja/akhir pekan) dan jenis layanan (jenis_moda).

Kelengkapan data

- Tidak ditemukan missing value di keempat kolom.
- Tidak ada baris duplikat, termasuk duplikat kombinasi tanggal + moda.
- Tujuh moda memiliki data lengkap selama 974 hari (masing-masing 13,8% dari data). MIKROTRANS hanya 243 hari (3,4%) karena baru tercatat mulai 1 Januari 2026.

Statistik dasar per moda

Tabel 4 Statistik Jumlah Penumpang per Hari per Moda (CV = std/mean)

Moda	Rata-rata	Median	Std	Min	Maks	CV
TRANSJAKARTA	987.644	988.669	296.713	125.239	1.478.815	0,30
KRL	956.062	990.016	210.054	0	2.267.378	0,22
MIKROTRANS	511.138	562.583	102.758	149.467	631.146	0,20
MRT	120.487	130.682	36.418	13.197	202.814	0,30
BUS SEKOLAH	24.243	35.923	20.446	0	55.983	0,84
KCI COMMUTER BANDARA	6.458	6.375	1.848	0	23.822	0,29
LRT	3.548	3.419	900	1.450	11.235	0,25
KAPAL	3.359	1.911	3.249	144	21.846	0,97

Secara keseluruhan, rata-rata penumpang per hari adalah 307.515 dengan median hanya 40.401 dan CV 1,44. Selisih rata-rata dan median yang besar menunjukkan data sangat miring karena dicampur dari moda dengan skala yang sangat berbeda.

Masalah kualitas data yang ditemukan

Tabel 5 Temuan Kualitas Data

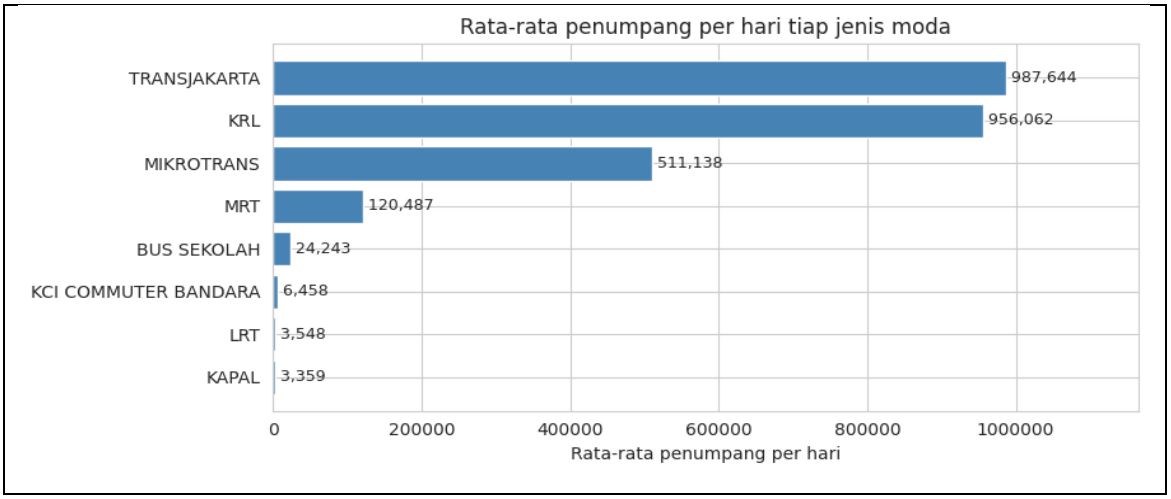
No	Masalah	Bukti	Implikasi
1	Perbedaan skala sangat besar antarmoda	Rata-rata TransJakarta sekitar 987 ribu vs Kapal sekitar 3,4 ribu per hari	Clustering berbasis jarak akan didominasi moda besar, sehingga perlu log-transform dan scaling

No	Masalah	Bukti	Implikasi
2	Distribusi miring dan memiliki beberapa puncak	Skewness 1,19; setelah log tampak beberapa gundukan terpisah	Statistik gabungan menyesatkan, sehingga analisis dilakukan per moda
3	Nilai nol mencurigakan pada KRL dan KCI Bandara	Bernilai 0 pada 16-17 Desember 2024 (Senin-Selasa, hari kerja)	Kemungkinan data tidak tercatat, diperlakukan sebagai missing
4	Nilai nol wajar pada Bus Sekolah	82 hari bernilai 0, bertepatan dengan libur sekolah	Dipertahankan karena memang pola layanan
5	Outlier (metode IQR per moda)	Kapal 6,3%, LRT 4,4%, KCI Bandara 3,5%, KRL 2,6%; Kapal maks 21.846; KRL lebih dari 2,1 juta pada Desember 2025	Outlier Kapal adalah pola libur nyata, dipertahankan; lonjakan KRL dipertahankan sementara dan perlu diverifikasi
6	Dugaan perubahan pencatatan TransJakarta/MIKROTRANS	TransJakarta turun dari sekitar 1,14 juta (2025) ke 0,68 juta (2026) saat MIKROTRANS mulai tercatat	Dicatat sebagai keterbatasan dalam interpretasi cluster

C. EDA dan Initial Findings

Sebelum visualisasi, dari kolom tanggal dibentuk fitur waktu dasar untuk eksplorasi: is_weekend (Sabtu-Minggu = 1), tipe_hari (Weekday/Weekend), dan bulan_tahun.

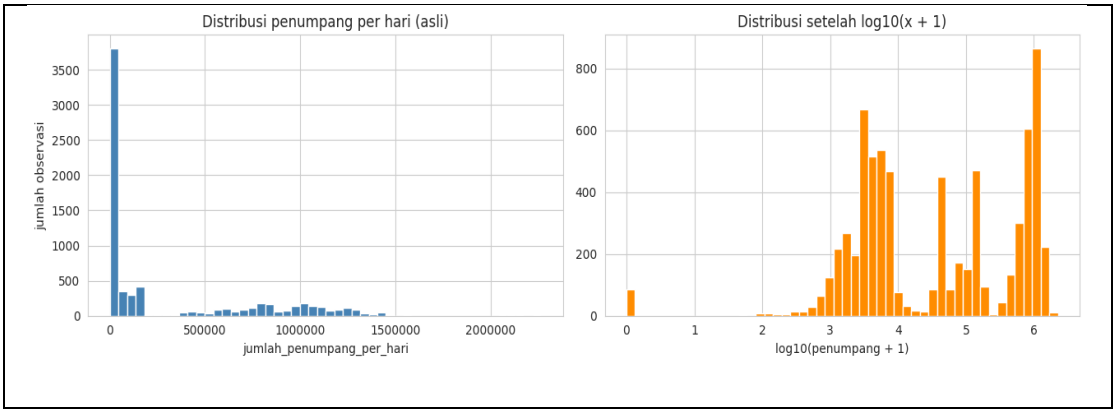
1. Rata-rata penumpang per moda



Gambar 1 Rata-rata Penumpang per Hari Tiap Jenis Moda

- Temuan: volume penumpang terkonsentrasi pada TransJakarta dan KRL, masing-masing sekitar 1 juta per hari.
- Bukti: MIKROTRANS sekitar 511 ribu, MRT sekitar 120 ribu, sedangkan Bus Sekolah, KCI Bandara, LRT, dan Kapal hanya ribuan sampai puluhan ribu.
- Interpretasi: ada tiga tingkat skala layanan, yaitu massal (TransJakarta, KRL, MIKROTRANS), menengah (MRT, Bus Sekolah), dan kecil/khusus (KCI Bandara, LRT, Kapal).
- Implikasi: tanpa transformasi, jarak pada clustering akan didominasi TransJakarta dan KRL, sehingga perlu log-transform dan scaling.

2. Distribusi jumlah penumpang (histogram)

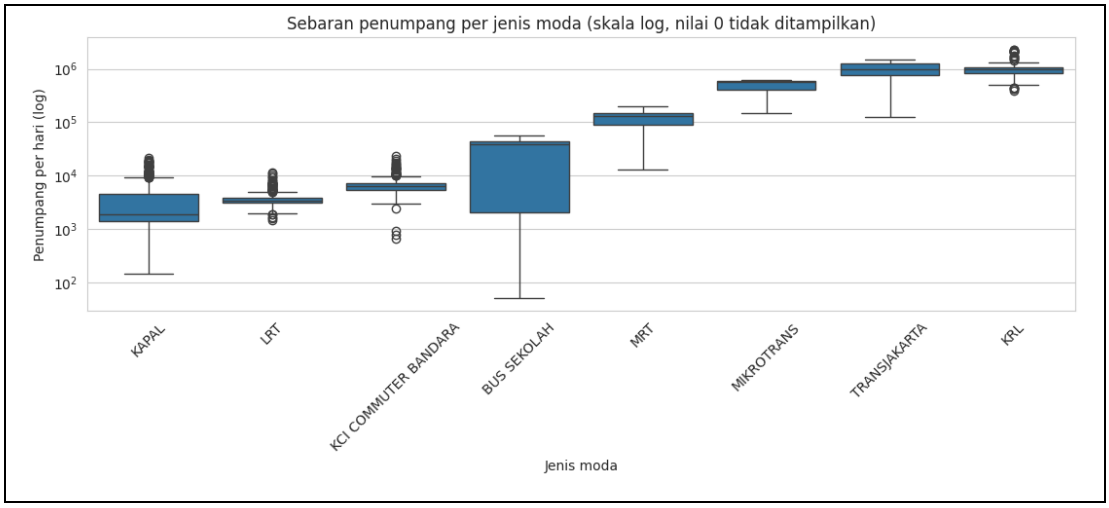


Gambar 2 Histogram Jumlah Penumpang Sebelum dan Sesudah Transformasi Log

- Temuan: distribusi asli miring ke kanan dan memiliki beberapa puncak.

- Bukti: skewness 1,19; sebagian besar observasi menumpuk di dekat nol dan sebagian lain di 0,5-1,5 juta. Setelah log, skewness menjadi -0,48 dan terlihat beberapa gundukan terpisah.
- Interpretasi: setiap gundukan sesuai dengan kelompok skala moda, sehingga histogram gabungan sebenarnya campuran beberapa populasi.
- Implikasi: transformasi log diperlukan dan distribusi dianalisis per moda.

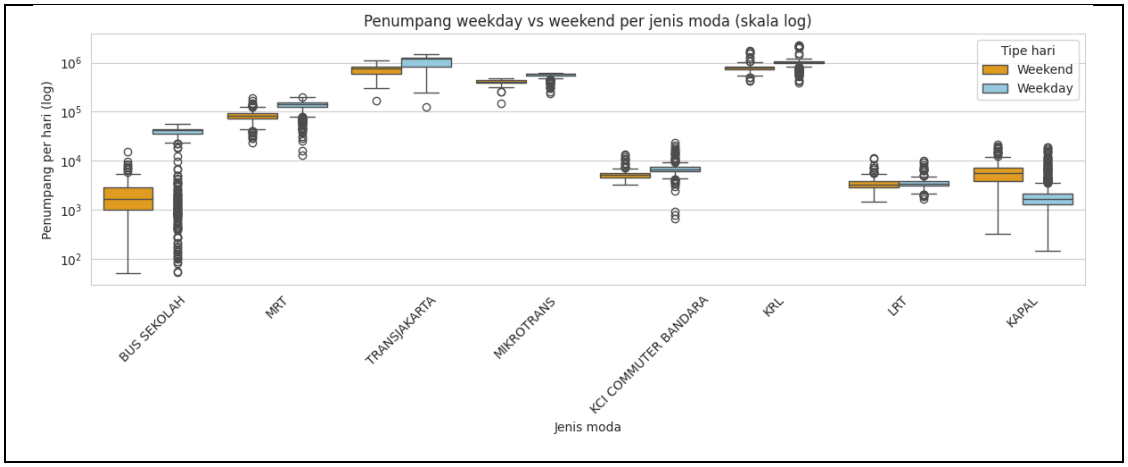
3. Sebaran penumpang per moda (boxplot)



Gambar 3 Boxplot Sebaran Penumpang per Jenis Moda (Skala Log)

- Temuan: besarnya naik-turun penumpang harian berbeda antarmoda.
- Bukti: kotak Bus Sekolah dan Kapal paling lebar, sedangkan kotak KRL, MRT, dan MIKROTRANS sempit. Titik di luar kotak paling banyak pada Kapal, LRT, KCI Bandara, dan KRL.
- Interpretasi: moda untuk perjalanan kerja cenderung stabil, sedangkan moda wisata atau layanan khusus lebih fluktuatif.
- Implikasi: tingkat kestabilan (CV) dapat dipakai untuk membedakan moda, dan hari lonjakan tidak dibuang karena merupakan pola nyata.

4. Hari kerja vs akhir pekan per moda



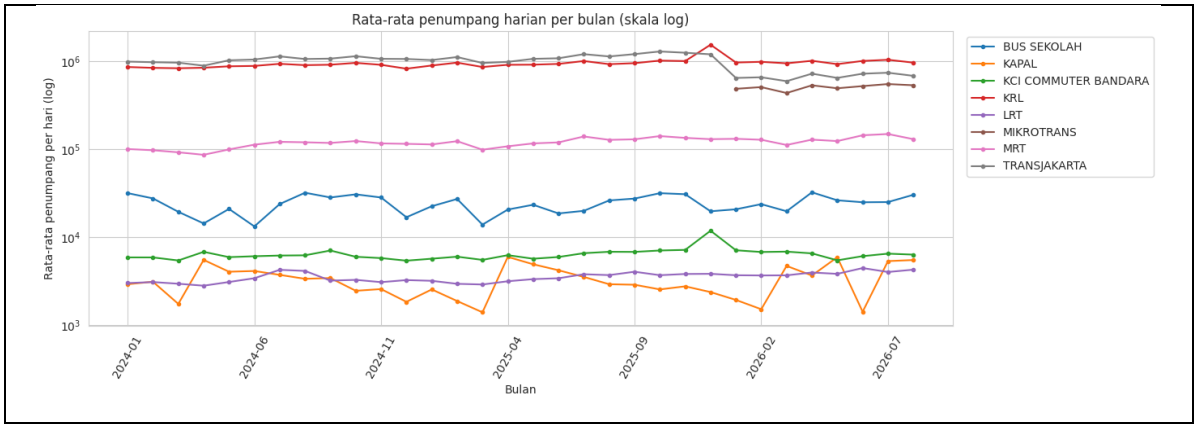
Gambar 4 Perbandingan Penumpang Weekday vs Weekend per Moda

Tabel 6 Median Penumpang Weekday vs Weekend

Moda	Median weekday	Median weekend	Rasio weekend/weekday
BUS SEKOLAH	41.202	1.405	0,03
MRT	139.957	82.615	0,59
TRANSJAKARTA	1.208.789	750.203	0,62
MIKROTRANS	585.117	407.397	0,70
KCI COMMUTER BANDARA	6.725	5.151	0,77
KRL	1.024.636	785.787	0,77
LRT	3.450	3.316	0,96
KAPAL	1.652	5.517	3,34

- Temuan: ramai atau sepinya akhir pekan bergantung pada jenis layanan. Hanya Kapal yang lebih ramai di akhir pekan.
- Interpretasi: ada tiga pola utama: (1) komuter, turun di akhir pekan; (2) layanan sekolah, hampir berhenti di akhir pekan; (3) rekreasi, naik di akhir pekan. LRT hampir sama antara hari kerja dan akhir pekan.
- Implikasi: rasio weekend/weekday paling jelas menangkap pengaruh waktu, sehingga dipakai sebagai fitur clustering.

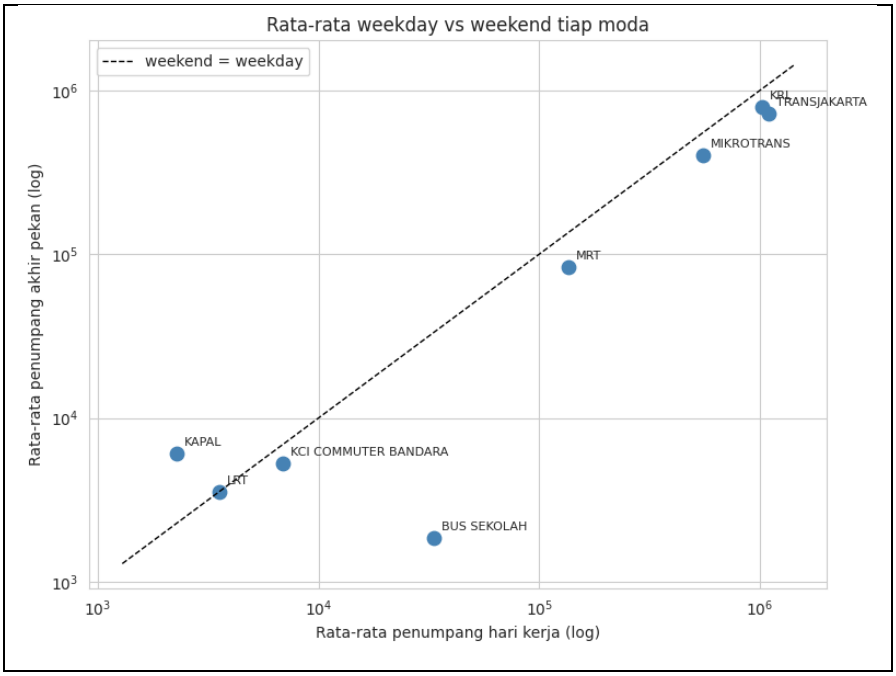
5. Tren bulanan per moda



Gambar 5 Tren Rata-rata Penumpang Harian per Bulan

- Temuan 1: TransJakarta turun tajam mulai 2026, dari rata-rata sekitar 1,04 juta (2024) dan 1,14 juta (2025) menjadi 0,68 juta (2026). Penurunan terjadi bersamaan dengan mulai tercatatnya MIKROTRANS (sekitar 0,5 juta). Penurunan bulanan terlihat jelas dari 1,21 juta (Desember 2025) ke 0,65 juta (Januari 2026).
- Interpretasi: kemungkinan besar penumpang MIKROTRANS sebelumnya dihitung sebagai TransJakarta, lalu dicatat terpisah mulai 2026. Jadi ini bukan penurunan penumpang yang sebenarnya.
- Temuan 2: KRL melonjak pada Desember 2025 (sekitar 1,55 juta per hari dibanding sekitar 1 juta pada bulan lain). Penyebabnya belum dapat dipastikan dan perlu dicek ke sumber data.
- Temuan 3: di luar dua hal tersebut, moda komuter (KRL, MRT, TransJakarta) cukup stabil tiap bulan, sedangkan Kapal dan Bus Sekolah naik-turun mengikuti musim libur.

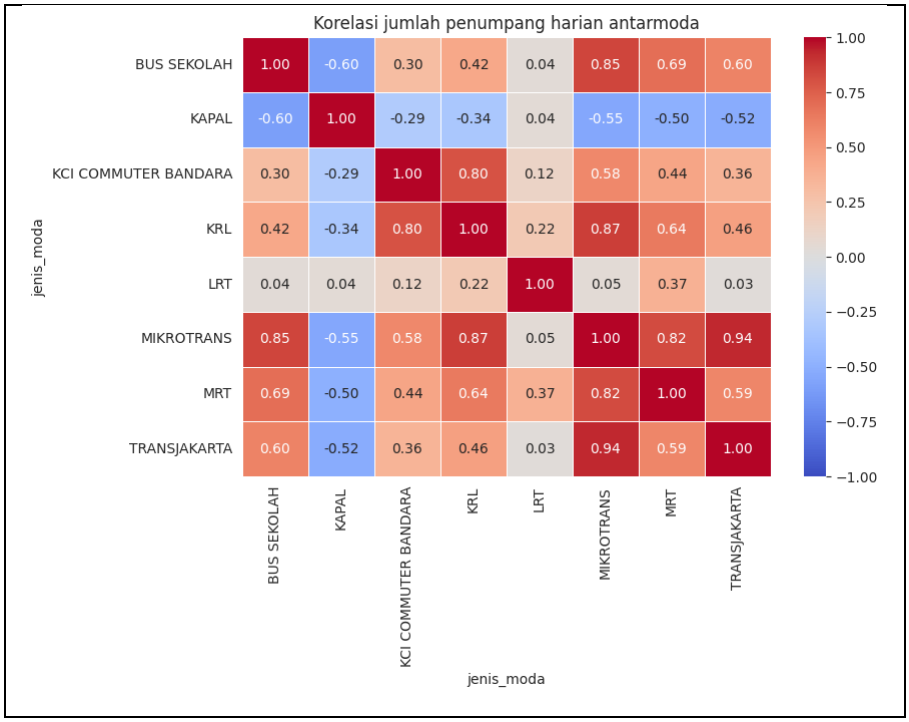
6. Hubungan weekday dan weekend (scatter plot)



Gambar 6 Scatter Plot Rata-rata Weekday vs Weekend per Moda

- Temuan: posisi moda terhadap garis diagonal (weekend = weekday) membedakan pola penggunaannya.
- Bukti: TransJakarta, KRL, MIKROTRANS, MRT, dan KCI Bandara berada di bawah garis; Bus Sekolah paling jauh di bawah; LRT hampir tepat di garis; Kapal satu-satunya di atas garis.
- Implikasi: skala penumpang (posisi sepanjang sumbu) dan rasio weekend/weekday (posisi terhadap garis) sudah cukup untuk memisahkan moda ke beberapa kelompok.

7. Korelasi pola harian antarmoda



Gambar 7 Heatmap Korelasi Jumlah Penumpang Harian Antarmoda

- Temuan: moda komuter ramai dan sepi secara bersamaan, sedangkan Kapal berlawanan arah.
- Bukti: korelasi MIKROTRANS-TransJakarta sekitar 0,94 (periode 2026), MRT-Bus Sekolah sekitar 0,69, TransJakarta-MRT sekitar 0,59. Kapal berkorelasi negatif dengan Bus Sekolah (sekitar -0,60), TransJakarta (sekitar -0,52), dan MRT (sekitar -0,50). LRT hampir tidak berkaitan dengan moda lain.
- Interpretasi: pada hari kerja dan hari sekolah moda komuter ramai bersama, sedangkan pada akhir pekan atau libur Kapal ramai saat moda lain sepi.

Ringkasan temuan awal EDA

1. Ada tiga tingkat skala layanan yang sangat berbeda, sehingga perlu log-transform dan scaling.
2. Pola waktu (rasio weekend/weekday) membedakan moda komuter, layanan sekolah, layanan netral (LRT), dan rekreasi (Kapal).
3. Kestabilan harian (CV) membedakan moda komuter yang stabil dari Kapal dan Bus Sekolah yang fluktuatif.
4. Ketiga aspek tersebut menjadi dasar pembentukan fitur clustering pada bagian E.

D. Preprocessing

Preprocessing mengubah 7.061 data harian menjadi tabel 8 moda x 3 fitur yang sudah setara skalanya. Ringkasan langkahnya:

Tabel 7 Langkah Preprocessing

No	Langkah	Alasan
1	Nilai 0 pada KRL dan KCI Bandara (16-17 Desember 2024) diubah menjadi NaN	Bukan nol sebenarnya; jika dibiarkan akan menurunkan rata-rata dan menaikkan CV
2	Membuat fitur waktu is_weekend dari tanggal	Diperlukan untuk menghitung rasio weekend/weekday
3	Agregasi data harian menjadi 1 baris per moda + pembentukan fitur	Unit analisis adalah moda
4	Outlier tidak dihapus	Lonjakan libur (misalnya Kapal saat Lebaran) adalah pola nyata yang ingin ditangkap
5	Tidak dilakukan encoding	jenis_moda menjadi identitas baris setelah agregasi, bukan fitur
6	Log-transform rata_penumpang + StandardScaler untuk semua fitur, dalam satu Pipeline	Algoritma clustering berbasis jarak; tanpa ini fitur skala akan mendominasi

Penanganan nilai hilang dan data bermasalah

Dataset tidak memiliki missing value secara eksplisit, tetapi ditemukan 4 nilai nol yang mencurigakan, yaitu KRL dan KCI Commuter Bandara pada 16 dan 17 Desember 2024. Kedua tanggal tersebut adalah hari kerja (Senin-Selasa), sehingga nilai 0 kemungkinan besar berarti data tidak tercatat, bukan tidak ada penumpang.

Keempat nilai tersebut diubah menjadi NaN dan tidak diisi (tidak diimputasi). Pandas otomatis melewati NaN saat agregasi, sehingga KRL dan KCI Bandara dihitung dari 972 hari yang valid. Pilihan ini lebih jujur daripada mengisi dengan nilai buatan, karena jumlahnya hanya 4 dari 7.061 baris.

Sebaliknya, 82 nilai nol pada Bus Sekolah dipertahankan, karena bertepatan dengan libur sekolah dan memang mencerminkan pola layanan.

Penanganan outlier

Outlier dideteksi dengan metode IQR yang dihitung per moda, karena skala antarmoda sangat berbeda. Outlier tidak dihapus maupun diubah:

- Lonjakan Kapal saat libur panjang (misalnya 21.846 penumpang pada 13 April 2024) adalah pola rekreasi yang nyata dan justru ditangkap oleh fitur rasio weekend/weekday dan CV.
- Lonjakan KRL di atas 2,1 juta pada Desember 2025 dipertahankan sementara karena penyebabnya belum dapat dikonfirmasi ke penyedia data.

Transformasi dan scaling

Transformasi dibungkus dalam satu ColumnTransformer:

- rata_penumpang: log1p lalu StandardScaler, untuk meredam perbedaan skala dari ribuan sampai hampir 1 juta.
- rasio_weekend_weekday dan cv_harian: langsung StandardScaler, karena nilainya sudah berada pada rentang kecil (sekitar 0,06-2,67 dan 0,20-0,97).

Setelah transformasi, setiap fitur memiliki rata-rata 0 dan simpangan baku sekitar 1, sehingga ketiganya berpengaruh setara pada perhitungan jarak.

Tabel 8 Data Setelah Preprocessing (Siap Clustering)

Moda	log_rata_ penumpang	rasio_weekend_ weekday	cv_harian
BUS SEKOLAH	-0,37	-1,19	1,49
KAPAL	-1,22	2,48	1,93
KCI COMMUTER BANDARA	-0,94	-0,20	-0,49
KRL	1,22	-0,18	-0,73
LRT	-1,20	0,12	-0,59
MIKROTRANS	0,95	-0,26	-0,77
MRT	0,33	-0,41	-0,42
TRANSJAKARTA	1,24	-0,35	-0,42

Pencegahan data leakage

- Clustering tidak memiliki target, sehingga tidak ada risiko kebocoran label ke fitur.
- jenis_moda tidak dipakai sebagai fitur, sehingga cluster tidak "dibocorkan" oleh nama moda dan murni berdasarkan pola penumpang.

- Semua transformasi (log dan scaling) berada dalam satu ColumnTransformer/Pipeline, sehingga langkah yang sama dapat dijalankan ulang secara konsisten.
- Pada uji kestabilan (bagian G), preprocessing dihitung ulang di setiap fold hanya dari hari yang dipakai (clone(preprocessor)), sehingga statistik scaling tidak memakai data dari hari yang dibuang.

E. Initial Feature Engineering

Data mentah hanya memiliki satu variabel numerik (jumlah_penumpang_per_hari), sehingga fitur clustering harus dibentuk sendiri. Berdasarkan temuan EDA, dibentuk tiga fitur per moda yang masing-masing mewakili satu aspek pola penggunaan.

Tabel 9 Fitur Hasil Rekayasa

Fitur	Dibentuk dari	Aspek yang ditangkap	Alasan
log_rata_penumpang	log1p(rata-rata penumpang harian) per moda	Skala layanan	Membedakan moda massal, menengah, dan kecil sambil meredam perbedaan skala yang sangat besar
rasio_weekend_weekday	rata-rata penumpang akhir pekan / rata-rata hari kerja	Waktu	Di bawah 1 = lebih sepi di akhir pekan (komuter/sekolah), sekitar 1 = netral, di atas 1 = lebih ramai di akhir pekan (rekreasi)
cv_harian	std / mean penumpang harian per moda	Kestabilan	Bebas skala, sehingga moda kecil dan besar dapat dibandingkan langsung

Nilai fitur setiap moda (skala asli, setelah 4 nilai nol mencurigakan ditangani):

Tabel 10 Nilai Fitur per Moda (Skala Asli)

Moda	Rata-rata penumpang	Rasio weekend/weekday	CV harian
TRANSJAKARTA	987.644	0,66	0,30
KRL	958.029	0,78	0,21
MIKROTRANS	511.138	0,72	0,20
MRT	120.487	0,61	0,30
BUS SEKOLAH	24.243	0,06	0,84
KCI COMMUTER BANDARA	6.471	0,77	0,28
LRT	3.548	0,99	0,25
KAPAL	3.359	2,67	0,97

Hasil awal:

- rasio_weekend_weekday membedakan empat pola dengan jelas: Bus Sekolah (0,06, hampir berhenti di akhir pekan), moda komuter (0,6-0,8, turun di akhir pekan), LRT (0,99, hampir sama), dan Kapal (2,67, lebih ramai di akhir pekan).
- log_rata_penumpang membedakan tiga tingkat skala: besar (TransJakarta, KRL, MIKROTRANS sekitar 13-14), menengah (MRT 11,7; Bus Sekolah 10,1), dan kecil (KCI Bandara, LRT, Kapal sekitar 8-9).
- cv_harian tinggi pada Kapal (0,97) dan Bus Sekolah (0,84), dan rendah pada moda komuter (0,2-0,3).

Dampak yang diharapkan: pengelompokan didasarkan pada skala, pola waktu, dan kestabilan penggunaan, bukan pada jumlah penumpang mentah yang didominasi moda besar. Dengan demikian, moda kecil dengan pola waktu berbeda (misalnya Kapal dan LRT) dapat dipisahkan meskipun jumlah penumpangnya mirip.

Uji awal dampak fitur (analisis sensitivitas): untuk memeriksa kontribusi setiap fitur, clustering diulang dengan beberapa variasi himpunan fitur. Hasilnya, menghapus cv_harian atau mengganti rasio dengan versi berbasis median tidak mengubah anggota cluster (ARI =

1). Namun menghapus skala penumpang mengubah hasil secara drastis (ARI 0,30 pada k = 3 dan 0,10 pada k = 4). Artinya, skala penumpang adalah fitur paling menentukan, sedangkan cv_harian lebih berperan sebagai penguat interpretasi. Detail hasil ada di bagian H.

F. Baseline dan Initial Candidate Models

Baseline: K-Means k = 3

Baseline yang dipakai adalah K-Means dengan konfigurasi awal, sesuai panduan untuk proyek unsupervised.

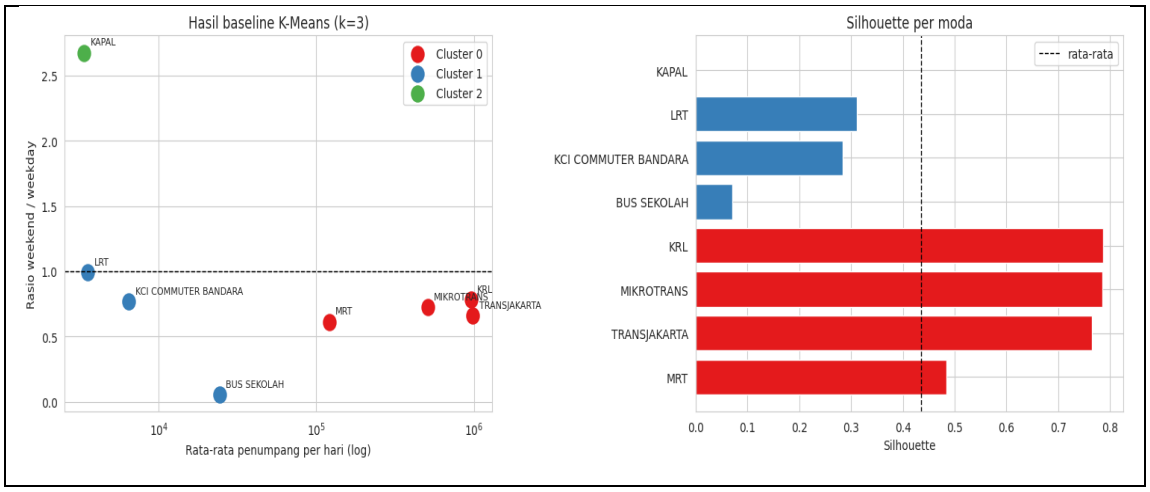
Tabel 11 Konfigurasi Baseline

Parameter	Nilai	Alasan
n_clusters	3	Dari EDA terlihat 3 pola: komuter (turun di akhir pekan), rekreasi (naik di akhir pekan), dan layanan sekolah (hampir berhenti di akhir pekan). Nilai ini belum dioptimasi
n_init	10	K-Means dijalankan 10 kali dengan titik awal berbeda, lalu diambil hasil terbaik
random_state	42	Agar hasil dapat direproduksi

Hasil baseline:

Tabel 12 Hasil Baseline K-Means k = 3 (Inertia 4,738; Silhouette 0,435)

Cluster	Anggota	Rata-rata penumpang	Rasio weekend/ weekday	CV	Silhouette rata-rata
0	KRL, MIKROTRANS, MRT, TransJakarta	644.324	0,69	0,25	0,70
1	Bus Sekolah, KCI Bandara, LRT	11.421	0,61	0,46	0,22
2	Kapal	3.359	2,67	0,97	0,00



Gambar 8 Hasil Baseline K-Means k = 3 dan Silhouette per Moda

Baseline sudah memisahkan komuter massal dan rekreasi (Kapal). Namun Bus Sekolah tergabung dengan LRT dan KCI Bandara hanya karena sama-sama berpenumpang sedikit, padahal pola akhir pekannya sangat berbeda (rasio 0,06 vs 0,99). Hal ini terlihat dari silhouette Bus Sekolah yang hanya 0,07.

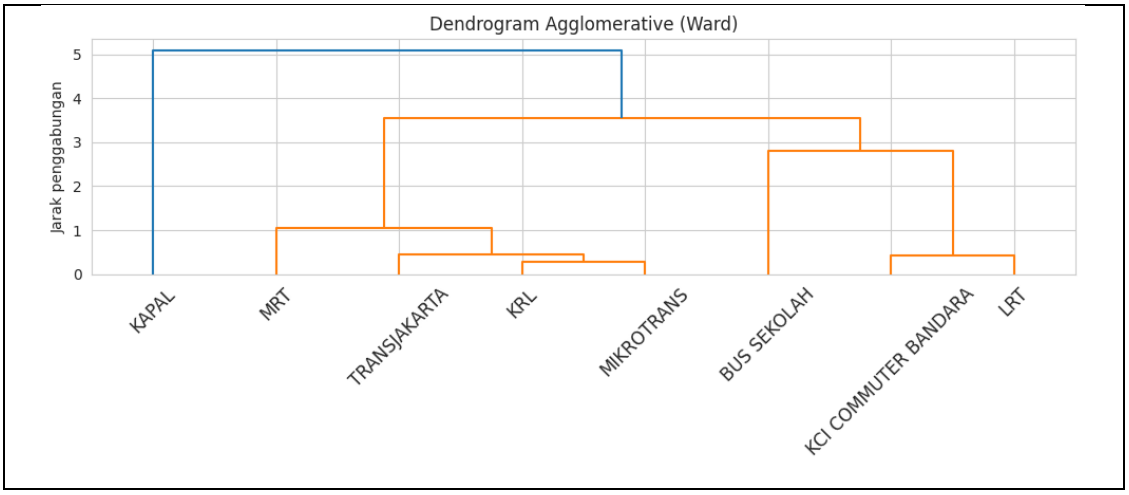
Kandidat model awal

Tabel 13 Kandidat Model Awal

Model	Konfigurasi	Alasan pemilihan
Baseline	K-Means, k = 3	Konfigurasi awal dari intuisi EDA
Kandidat 1	K-Means, k = 2 sampai 6	k = 3 belum diuji, sehingga perlu bukti nilai k yang paling sesuai
Kandidat 2	Agglomerative Clustering (linkage Ward), k = 2 sampai 6	Tidak bergantung pada titik awal acak dan cocok untuk data kecil; dendrogram memperlihatkan urutan penggabungan moda. Ward meminimalkan varians dalam cluster seperti K-Means, sehingga hasilnya sebanding
Kandidat 3	Gaussian Mixture Model (covariance diag), k = 2 sampai 6	Pendekatan berbasis probabilitas, berbeda dari pendekatan berbasis jarak. Covariance diag dipilih karena data hanya 8 moda sehingga covariance penuh tidak stabil
Kandidat 4	Agglomerative (linkage average dan complete), k = 2 sampai 6	Menguji apakah hasil Ward bergantung pada jenis linkage

DBSCAN tidak dipakai karena data hanya 8 titik, sehingga parameter kepadatan (eps, min_samples) tidak dapat ditentukan secara bermakna.

Dendrogram Agglomerative



Gambar 9 Dendrogram Agglomerative Clustering (Ward)

Pada dendrogram, moda yang paling mirip bergabung lebih dulu: KRL dan MIKROTRANS, lalu TransJakarta, lalu MRT (jarak sampai sekitar 1,1), serta LRT dan KCI Bandara (sekitar 0,4). Bus Sekolah baru bergabung dengan LRT-KCI pada jarak sekitar 2,8, dan Kapal bergabung paling akhir (sekitar 5,1). Artinya Kapal adalah moda paling berbeda, disusul Bus Sekolah. Jika dendrogram dipotong di antara jarak 1,1 dan 2,8, hasilnya 4 cluster.

G. Evaluation Design

Pembagian data

Tidak dilakukan train-test split, dengan alasan:

1. Clustering tidak memiliki target, sehingga tidak ada "jawaban benar" yang perlu diuji pada data test.
2. Tujuan analisis adalah mendeskripsikan pengelompokan 8 moda yang ada, bukan memprediksi data baru.
3. Data hanya 8 baris; jika dibagi, sebagian moda tidak ikut dikelompokkan.

Validation set juga tidak diperlukan, karena pemilihan k dilakukan dengan metrik internal (silhouette dan Elbow) pada seluruh 8 moda.

Metode validasi: uji kestabilan 5-fold pada tanggal

Karena tidak ada data uji, validasi difokuskan pada **kestabilan**: apakah cluster tetap sama jika sebagian data harian dibuang.

1. Ke-974 tanggal dibagi menjadi 5 bagian acak (KFold, shuffle=True, random_state=42).
2. Pada setiap fold, satu bagian (sekitar 20% hari) dibuang.
3. Fitur setiap moda dihitung ulang dari sekitar 80% hari sisanya.
4. Preprocessing (log + scaling) di-fit ulang hanya pada data fold tersebut (clone(preprocessor)).
5. Clustering dijalankan ulang, lalu hasilnya dibandingkan dengan cluster dari data penuh menggunakan ARI, dan dihitung juga silhouette-nya.

Pembagian dilakukan pada tanggal, bukan pada moda, karena moda adalah unit yang dikelompokkan sehingga kedelapannya harus selalu ada. Pembagian fold dilakukan secara acak, sehingga uji ini menilai ketahanan cluster terhadap hilangnya sebagian hari (±20% per fold). Uji ini belum mencakup hilangnya periode tertentu (misalnya 2026) atau moda tertentu.

Selain itu, kestabilan terhadap titik awal acak K-Means diuji dengan menjalankan baseline pada 5 random_state berbeda (0, 1, 7, 21, 99).

Metrik evaluasi

Tabel 14 Metrik Evaluasi

Metrik	Arti	Arah lebih baik	Peran
Silhouette score	Seberapa jelas setiap moda terpisah dari cluster lain (-1 sampai 1)	Lebih tinggi	Metrik utama
Inertia (Elbow)	Jumlah jarak kuadrat ke pusat cluster (khusus K-Means)	Dilihat titik "siku"	Metrik utama pemilihan k
Davies-Bouldin index	Rata-rata kemiripan cluster dengan cluster terdekatnya	Lebih rendah	Pendukung
Calinski-Harabasz index	Rasio jarak antar-cluster terhadap jarak dalam cluster	Lebih tinggi	Pendukung

Metrik	Arti	Arah lebih baik	Peran
Adjusted Rand Index (ARI)	Kesamaan dua hasil pengelompokan	Mendekati 1 = sama	Uji kestabilan dan kesamaan antarmodel
Ukuran dan profil cluster	Jumlah anggota dan rata-rata fitur tiap cluster	Dapat ditafsirkan	Interpretasi

Alasan pemilihan metrik

- Silhouette dipilih sebagai metrik utama karena dapat dihitung tanpa label dan juga per moda, sehingga terlihat moda mana yang kurang cocok dengan cluster-nya.
- Elbow dipakai bersama silhouette untuk memilih k. Jika keduanya menunjuk k yang sama, pilihan k lebih meyakinkan.
- Davies-Bouldin dan Calinski-Harabasz hanya menjadi pendukung. Dengan hanya 8 moda, keduanya cenderung memilih k besar karena cluster kecil (1-2 anggota) otomatis terlihat rapat.
- ARI bukan penilai kualitas cluster, tetapi dipakai untuk mengukur apakah hasil berubah antarfold, antar-random_state, atau antaralgoritma.
- Silhouette cluster beranggota satu otomatis bernilai 0. Karena itu silhouette selalu dibaca bersama ukuran cluster.

H. Initial Results and Analysis

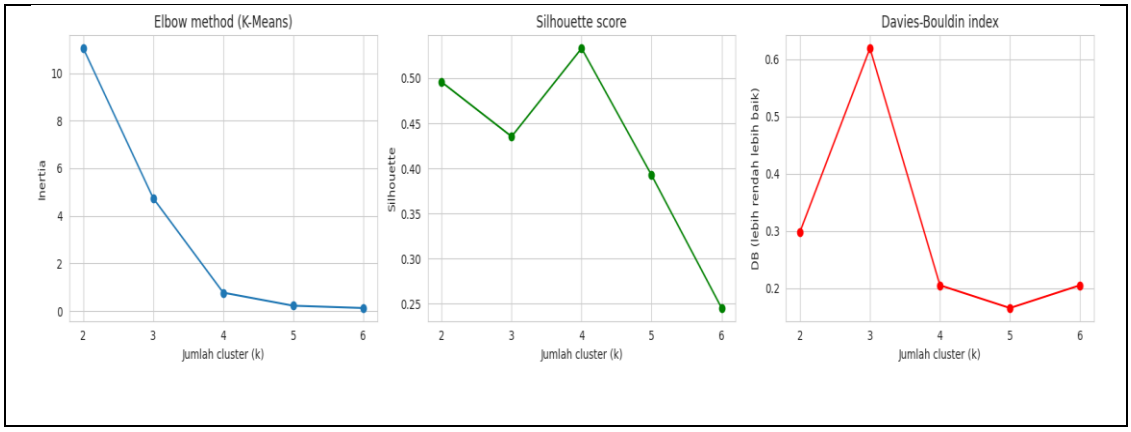
Hasil awal menunjukkan k = 4 adalah konfigurasi terbaik: silhouette naik dari 0,435 (baseline k = 3) menjadi 0,533, semua algoritma menghasilkan cluster yang sama, dan hasilnya stabil di semua fold.

1. Eksperimen jumlah cluster (k = 2 sampai 6)

Tabel 15 Hasil K-Means dan Agglomerative Ward untuk k = 2 sampai 6 (keduanya identik)

k	Silhouette	Davies-Bouldin	Calinski-Harabasz	Inertia	Ukuran cluster
2	0,496	0,30	7,05	11,04	7-1
3 (baseline)	0,435	0,62	10,16	4,74	4-3-1
4	0,533	0,20	39,93	0,78	4-2-1-1

k	Silhouette	Davies-Bouldin	Calinski-Harabasz	Inertia	Ukuran cluster
5	0,393	0,17	78,60	0,23	3-2-1-1-1
6	0,245	0,20	73,64	0,13	2-2-1-1-1-1



Gambar 10 Elbow Method, Silhouette Score, dan Davies-Bouldin Index untuk k = 2 sampai 6

- **Elbow:** inertia turun tajam dari k = 2 (11,0) ke k = 3 (4,7) dan k = 4 (0,8), lalu hampir datar. Siku berada di k = 4.
- **Silhouette:** tertinggi di k = 4 (0,533), lalu turun di k = 5-6.
- k = 2 hanya memisahkan Kapal dari 7 moda lain, sehingga kurang informatif untuk tujuan proyek.
- Davies-Bouldin dan Calinski-Harabasz terus membaik sampai k = 5 karena cluster kecil otomatis terlihat rapat, sehingga hanya dipakai sebagai pendukung.

2. Perbandingan model pada k = 4

Tabel 16 Perbandingan Baseline dan Kandidat Model

Peran	Model	Silhouette	Davies-Bouldin	Calinski-Harabasz	Anggota cluster
Baseline	K-Means (k = 3)	0,435	0,62	10,16	Kapal / KRL, MIKROTRANS, MRT, TJ / Bus Sekolah, KCI, LRT
Kandidat 1	K-Means (k = 4)	0,533	0,20	39,93	KRL, MIKROTRANS, MRT, TJ / KCI,

Peran	Model	Silhouette	Davies-Bouldin	Calinski-Harabasz	Anggota cluster
					LRT / Bus Sekolah / Kapal
Kandidat 2	Agglomerative Ward (k = 4)	0,533	0,20	39,93	Sama dengan Kandidat 1
Kandidat 3	GMM diag (k = 4)	0,533	0,20	39,93	Sama dengan Kandidat 1
Kandidat 4	Agglomerative average/complete (k = 4)	0,533	0,20	39,93	Sama dengan Kandidat 1

Perbedaan hasil: pada k = 4 (dan k = 5), semua metode menghasilkan anggota cluster yang sama persis (ARI = 1). Perbedaan antaralgoritma baru muncul pada k lain. Pada k = 3, GMM serta linkage average/complete menghasilkan ukuran 6-1-1 dengan silhouette 0,346 (ARI 0,30 terhadap K-Means). Pada k = 2, GMM menghasilkan 6-2 (silhouette 0,404) sedangkan metode lain 7-1 (silhouette 0,496). Artinya struktur empat kelompok berasal dari data, bukan dari pilihan algoritma.

3. Analisis sensitivitas fitur

Tabel 17 Analisis Sensitivitas Fitur (K-Means)

Variasi fitur	k	Silhouette (ruang fitur sendiri)	ARI vs 3 fitur asli
A. 3 fitur (asli)	3 / 4	0,44 / 0,53	1,00 / 1,00
B. Tanpa cv_harian	3 / 4	0,50 / 0,48	1,00 / 1,00
C. Tanpa skala penumpang	3 / 4	0,65 / 0,31	0,30 / 0,10
D. Rasio memakai median	3 / 4	0,45 / 0,54	1,00 / 1,00

Skala penumpang adalah fitur paling menentukan: tanpa fitur ini, LRT bergabung dengan KRL dan MIKROTRANS pada k = 4. Silhouette 0,65 pada variasi C tidak berarti lebih baik, karena dihitung pada ruang fitur yang berbeda dan dipengaruhi cluster beranggota satu.

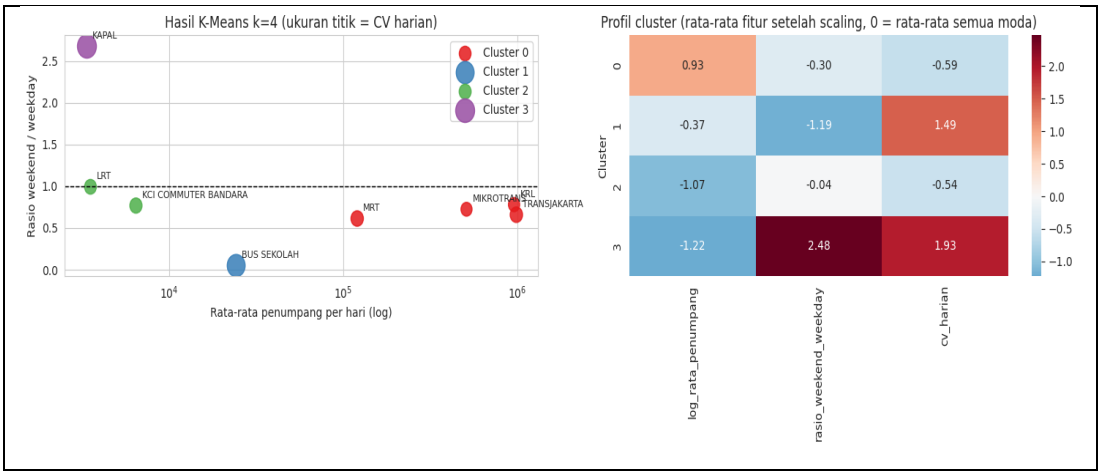
4. Hasil uji kestabilan

Tabel 18 Hasil Uji Kestabilan 5-Fold pada Tanggal

Model	Silhouette rata-rata (5 fold)	Std silhouette	ARI rata-rata vs data penuh
Baseline K-Means (k = 3)	0,435 (0,430-0,442)	0,005	1,000
K-Means (k = 4)	0,533 (0,530-0,535)	0,002	1,000
Agglomerative Ward (k = 4)	0,533 (0,530-0,535)	0,002	1,000

ARI = 1 di semua fold, artinya setiap moda tetap masuk cluster yang sama walaupun 20% hari dibuang. k = 4 juga lebih baik daripada k = 3 di setiap fold, sehingga keunggulannya bukan kebetulan. Baseline juga stabil terhadap titik awal acak (ARI = 1 pada 5 random_state berbeda).

5. Profil cluster terpilih (K-Means k = 4)



Gambar 11 Hasil K-Means k = 4 dan Heatmap Profil Cluster

Tabel 19 Profil Cluster K-Means k = 4

Cluster	Anggota	Rata-rata penumpang	Rasio weekend/ weekday	CV	Interpretasi
0	KRL, MIKROTRANS, MRT, TransJakarta (50%)	644.324	0,694	0,255	Komuter massal: penumpang terbanyak, turun sekitar 30% di akhir pekan, stabil
1	Bus Sekolah (12,5%)	24.243	0,056	0,843	Layanan sekolah: hampir berhenti di akhir pekan, fluktuatif
2	KCI Bandara, LRT (25%)	5.010	0,880	0,268	Layanan khusus stabil: penumpang sedikit, merata sepanjang minggu
3	Kapal (12,5%)	3.359	2,675	0,967	Rekreasi/wisata: naik di akhir pekan, paling fluktuatif

Dengan k = 4, masalah baseline teratasi karena Bus Sekolah kini menjadi cluster sendiri sesuai pola layanan sekolah yang terlihat di EDA. Dari sisi operasional, armada cluster 0 difokuskan pada hari kerja, armada Bus Sekolah dapat dialihkan saat akhir pekan dan libur sekolah, dan armada Kapal ditambah saat akhir pekan dan libur panjang.

6. Pemeriksaan PCA

PCA diuji untuk melihat apakah meringkas 3 fitur menjadi 2 komponen mengubah hasil. Dua komponen menyimpan 83,5% varians (PC1 64,7%, PC2 18,8%), dan hasil cluster-nya sama persis dengan tanpa PCA (ARI = 1, silhouette 0,533 pada ruang fitur asli). Karena fitur hanya 3 dan PCA mempersulit interpretasi, PCA tidak dipakai.

Keterbatasan dan hal yang perlu diperbaiki

1. Jumlah moda hanya 8, sehingga metrik mudah berubah oleh satu moda dan ada dua cluster beranggota satu (Bus Sekolah dan Kapal). Silhouette 8 moda (0,533) lebih rendah daripada rata-rata 6 moda non-singleton (0,711) karena cluster beranggota satu otomatis bernilai 0.
2. Uji kestabilan hanya mengubah hari, bukan moda. Menambah atau menghapus satu moda masih bisa mengubah hasil.
3. Perubahan pencatatan TransJakarta/MIKROTRANS (2026) dan lonjakan KRL Desember 2025 belum diverifikasi ke sumber data dan belum diuji dampaknya secara khusus.
4. Profil dihitung dari rata-rata seluruh periode, sehingga variasi musiman (libur Lebaran, libur sekolah) tidak tertangkap.
5. Pengaruh fitur rasio weekend/weekday belum diuji secara terpisah pada analisis sensitivitas.

I. Documentation and Next Plan

Dokumentasi

Seluruh eksperimen didokumentasikan dalam satu notebook Google Colab (UTS_Kelompok4_B02.ipynb) yang disusun per minggu, lengkap dengan kode, output, dan interpretasi di setiap langkah.

Tabel 20 Artefak Proyek

Artefak	Tautan / Keterangan
Notebook (Google Colab)	https://colab.research.google.com/drive/1D9IAD6pWsUYy6m1JIhZ3F-GTZeOzPWxy?usp=sharing
Repository GitHub	https://github.com/rifkyghifari/ML_PolaPenggunaanTransportasiUmum-B02-.git
Onedrive	https://mikroskilacid-my.sharepoint.com/:f:/g/personal/rifky_ghifari_students_mikroskil_ac_id/IgDOutoxiWZnTb7QYF3arSQHAX2j_b_7TeAVa-moFeOCj5c?e=Gzl6a2
Dataset	Jumlah Penumpang Angkutan Umum yang Terlayani per Hari | Satu Data Jakarta

Artefak	Tautan / Keterangan
File hasil	penumpang_raw.csv (data mentah), fitur_moda.csv (tabel fitur per moda)

Lingkungan pengembangan: Google Colab, Python 3, dengan library pandas, numpy, matplotlib, seaborn, scikit-learn (KMeans, AgglomerativeClustering, GaussianMixture, PCA, Pipeline, ColumnTransformer, KFold, metrik clustering), dan scipy (dendrogram). Seluruh eksperimen memakai random_state = 42 agar dapat direproduksi.

Catatan eksperimen

Tabel 21 Catatan Eksperimen

Minggu	Kegiatan	Hasil utama
2	Data understanding, EDA, rencana preprocessing, rekayasa fitur awal	6 masalah kualitas data teridentifikasi; 3 fitur dibentuk (skala, rasio weekend/weekday, CV)
3	Preprocessing, baseline K-Means k = 3, evaluasi awal	Silhouette 0,435; Bus Sekolah salah tempat (silhouette 0,07); stabil terhadap random_state
4	Eksperimen k = 2-6, Agglomerative, GMM, linkage lain, sensitivitas fitur	k = 4 terbaik (silhouette 0,533); semua algoritma identik pada k = 4
5	Validasi kestabilan 5-fold pada tanggal	ARI = 1 di semua fold; std silhouette di bawah 0,01
6	Model terpilih, profil cluster, pemeriksaan PCA	4 cluster: komuter massal, layanan sekolah, layanan khusus stabil, rekreasi; PCA tidak dipakai

Rencana pekerjaan setelah UTS sampai UAS

Tabel 22 Rencana Pasca-UTS

Tahap	Rencana	Tujuan
1	Uji leave-one-moda-out: menghapus satu moda bergantian lalu clustering ulang	Menguji dampak jumlah moda yang sedikit terhadap kestabilan cluster

Tahap	Rencana	Tujuan
2	Uji periode: membandingkan cluster dari data 2024-2025 dengan data 2026	Melihat pengaruh perubahan pencatatan TransJakarta/MIKROTRANS
3	Verifikasi lonjakan KRL Desember 2025 dan nol KRL/KCI Desember 2024 ke sumber data	Memastikan perlakuan data bermasalah sudah tepat
4	Uji sensitivitas fitur rasio weekend/weekday secara terpisah	Melengkapi analisis kontribusi setiap fitur
5	Menambah fitur musiman, misalnya rasio penumpang saat libur sekolah/hari besar terhadap hari biasa	Menangkap variasi musiman yang hilang karena profil dihitung dari rata-rata seluruh periode
6	Finalisasi model, merapikan notebook dan repository GitHub (README, struktur kode)	Menyiapkan artefak final yang konsisten dengan laporan
7	Menyusun laporan akhir dan bahan presentasi UAS	Final project UAS